Introdução e Conceitos de Linguagens Formais

Profa.Thatyana de Faria Piola Seraphim

Universidade Federal de Itajubá

thatyana@unifei.edu.br

Linguagens Formais

Introdução

- As **linguagens formais** foram desenvolvidas na década de 1950.
  - **Objetivo:** desenvolver teorias relacionadas com as linguagens naturais.
  - Logo foi verificado que esta teoria era importante para o estudo das linguagens de programação.
- Assim, o estudo das linguagens formais se desenvolveu de forma significativa e com diversos enfoques, principalmente:
  - Aplicações em análise léxica e sintática.
  - Modelagem de circuitos lógicos ou redes lógicas.
  - Aplicações com sistemas de animação, hipertexto e hipermídias.

Linguagens Formais

Introdução

- As linguagens formais se preocupam com os problemas sintáticos das linguagens de programação.
  - Assim, é importante introduzir primeiro os conceitos de sintaxe e de semântica de linguagens.
- O problema sintático foi reconhecido antes do problema semântico, sendo o primeiro a receber o tratamento adequado.
- Os problemas sintáticos são de tratamento mais simples, levando à ideia de que as questões das linguagens de programação se resumiam às questões de sintaxe.
- A teoria da sintaxe possui construções matemáticas bem definidas e universalmente reconhecidas.

Linguagens Formais

Introdução

- Uma linguagem de programação pode ser vista de duas formas:
  - Entidade livre sem qualquer significado associado.
  - Entidade juntamente com uma interpretação do seu significado.
- A **sintaxe** trata das propriedades da linguagem, como por exemplo, a verificação gramatical de programas.
  - Manipula os símbolos sem considerar os seus significados.
- A **semântica** dá uma interpretação para a linguagem, como por exemplo, um significado ou valor para um determinado programa.

Linguagens Formais

Introdução

- Para resolver qualquer problema real, é necessário dar uma interpretação semântica aos símbolos:
  - **Exemplo**: *estes símbolos representam os inteiros*
- Sintaticamente falando, não existe uma noção de programa **errado**:
  - simplesmente não é um programa da linguagem em questão.
- Um programa sintaticamente válido (**correto**), pode não ser o programa que o programador esperava escrever.

IMPORTANTE

A questão de considerar um programa **correto** ou **errado** deve considerar se o mesmo, modela de forma adequada o comportamento desejado.

Linguagens Formais

Hierarquia de Chomsky

- O estudo sistemático das linguagens formais teve um forte impulso no final da década de 1950, quando Noam Chomsky publicou dois artigos, apresentando a classificação hierárquica das linguagens.
  - A. N. Chomsky. "*Three models for the description language*". IEEE Transactions on Information Theory. Vol 2. N 3. Pages 113–124. 1956.
  - A. N. Chomsky. "*On certain formal properties of grammar*". Information and Control. Vol 2. Pages 137–167. 1959.
- O trabalho de Chomsky chamou a atenção de especialistas de outras áreas, em particular da computação, que viam por suas teorias, grande aplicabilidade para a formalização e o estudo sistemático de linguagens artificiais, especialmente as de computação.

Linguagens Formais

Hierarquia de Chomsky

- A classificação das linguagens proposta por Chomsky é conhecida como a **Hierarquia de Chomsky**.
- A **Hierarquia de Chomsky** tem como principal mérito agrupar as linguagens em classes, de tal forma que elas possam ser hierarquizadas de acordo com a sua complexidade.
  - Como resultado, é possível antecipar as propriedades fundamentais exibidas por uma determinada linguagem, ou mesmo surgir os modelos de implementação mais adequados à sua realização, conforme a classe a que pertença.
- O interesse prático pela Hierarquia de Chomsky se deve ao fato de ela viabilizar a escolha da forma mais econômica para a realização dos reconhecedores das linguagens.

- Essa escolha é feita de acordo com a classe a que elas pertençam nessa hierarquia, evitando o uso de formalismos mais complexos que o necessário.
  - E o emprego de reconhecedores desnecessariamente ineficientes para as linguagens de menor complexidade.
- De um ponto de vista da engenharia, a Hierarquia de Chomsky permite determinar e selecionar o modelo de implementação de menor custo para cada linguagem considerada.
- A Hierarquia de Chomsky define quatro classes distintas de linguagens, denominadas **tipos 0, 1, 2, e 3**.
  - As classes são geradas por gramáticas particularizadas por intermédio de restrições que são aplicadas ao formato das produções $\alpha \rightarrow \beta$.

Linguagens Formais

Hierarquia de Chomsky

- Gramáticas lineares são conhecidas como gramáticas do **tipo 3** e geram linguagens denominadas **regulares** ou simplesmente do **tipo 3**.
  - As linguagens regulares constituem a classe de linguagens mais simples dentro da Hierarquia de Chomsky.
- Uma gramática é dita **livre de contexto** ou do **tipo 2**, se suas produções possuírem apenas um símbolo não terminal em seu lado esquerdo e uma combinação qualquer de símbolos terminais e não terminais no lado direito.
- Toda gramática do tipo 3 se enquadra na definição de gramática do tipo 2.
  - É correto dizer que toda gramática do tipo 3 é também uma gramática do tipo 2

- Por outro lado, nem toda gramática do tipo 2 pode ser caracterizada como gramática do tipo 3.
  - Existe uma relação de inclusão própria entre o conjunto das gramáticas do tipo 3 e o conjunto das gramáticas de tipo 2.
- As gramáticas do **tipo 1**, também conhecidas como **sensíveis ao contexto** constituem a classe seguinte na Hierarquia de Chomsky.
  - A caracterização das gramáticas sensíveis ao contexto decorre da restrição imposta ao formato das produções de que:
    - o comprimento da cadeia do lado direito de cada produção seja no mínimo igual ao comprimento da cadeia do lado esquerdo.
    - Não havendo, possibilidade de redução do comprimento das formas sentenciais quando da realização de derivações de gramática deste tipo.

Linguagens Formais

Hierarquia de Chomsky

- Nem toda gramática do tipo 2 pode ser considerada uma gramática do tipo 1.
- Gramáticas do tipo 2 permitem a geração da cadeia vazia, ao passo que gramáticas do tipo 1 não prevêem essa possibilidade.
- Nem toda gramática do tipo 1 pode ser considerada gramática do tipo 2.
  - Em particular, aquelas que apresentam produções cujo lado esquerdo seja composto por cadeias de dois ou mais símbolos.
- No entanto, é possível provar que toda linguagem livre de contexto (tipo 2) é também uma linguagem sensível ao contexto (tipo 1).
  - O contrário não é verdadeiro, pois existem linguagens sensíveis ao contexto, que não podem ser geradas por gramáticas livres de contexto.

- As gramáticas pertencentes à última classe definida pela Hierarquia de Chomsky recebem a denominação de **irrestritas** ou do **tipo 0**.
- Trata-se de gramáticas sobre as quais não é imposta nenhuma restrição quanto ao formato de suas produções.
  - Exceto pelo fato de que o lado esquerdo das mesmas deve sempre conter pelo menos um símbolo não-terminal.

Símbolos Terminais e Não-terminais

exp → *exp* + *termo*
exp → *exp* - *termo*
exp → *termo*
termo → *termo* * *fator*
termo → *termo* / *fator*
termo → *fator*
fator → (*exp*)
fator → **id**

- **Símbolos terminais**: +, -, *, /, (,), id
- **Símbolos não-terminais**: *exp*, *termo* e *fator*
- **Símbolo inicial**: *exp*

Linguagens Formais

Hierarquia de Chomsky

- Diferentemente do que ocorre com as gramáticas sensíveis ao contexto, as formas sentenciais obtidas pela aplicação das regras de uma gramática irrestrita não possuem comprimento crescente:
  - elas podem aumentar ou diminuir de comprimento, conforme as produções que forem aplicadas.
- Às linguagens geradas por gramáticas do tipo 0 dá-se o nome de **recursivamente enumeráveis, irrestritas** ou do **tipo 0**.
- Toda gramática do tipo 1 também é uma gramática do tipo 0, porém o contrário não é verdadeiro.
- Toda linguagem sensível ao contexto pode também ser considerada uma linguagem irrestrita.

Linguagens Formais

Hierarquia de Chomsky

- Existem linguagens irrestritas que não podem ser geradas por qualquer gramática sensível ao contexto.
  - As linguagens sensíveis ao contexto constituem subconjunto próprio das linguagens irrestritas.
- A Hierarquia de Chomsky original estabelece que:
  1. Toda linguagem do tipo i, $0 \leq i \leq 3$ é gerada por uma gramática do tipo i.
  2. A classe de linguagens do tipo i, $1 \leq i \leq 3$ essa incluída na classe de linguagens $i-1$.
     - Toda linguagem do tipo i, $1 \leq i \leq 3$ é também uma linguagem do tipo $i-1$.
- No caso das linguagens do tipo 2 (livres de contexto), as regras acima são válidas apenas para linguagens que não contêm a cadeia vazia.

Linguagens Formais

Hierarquia de Chomsky

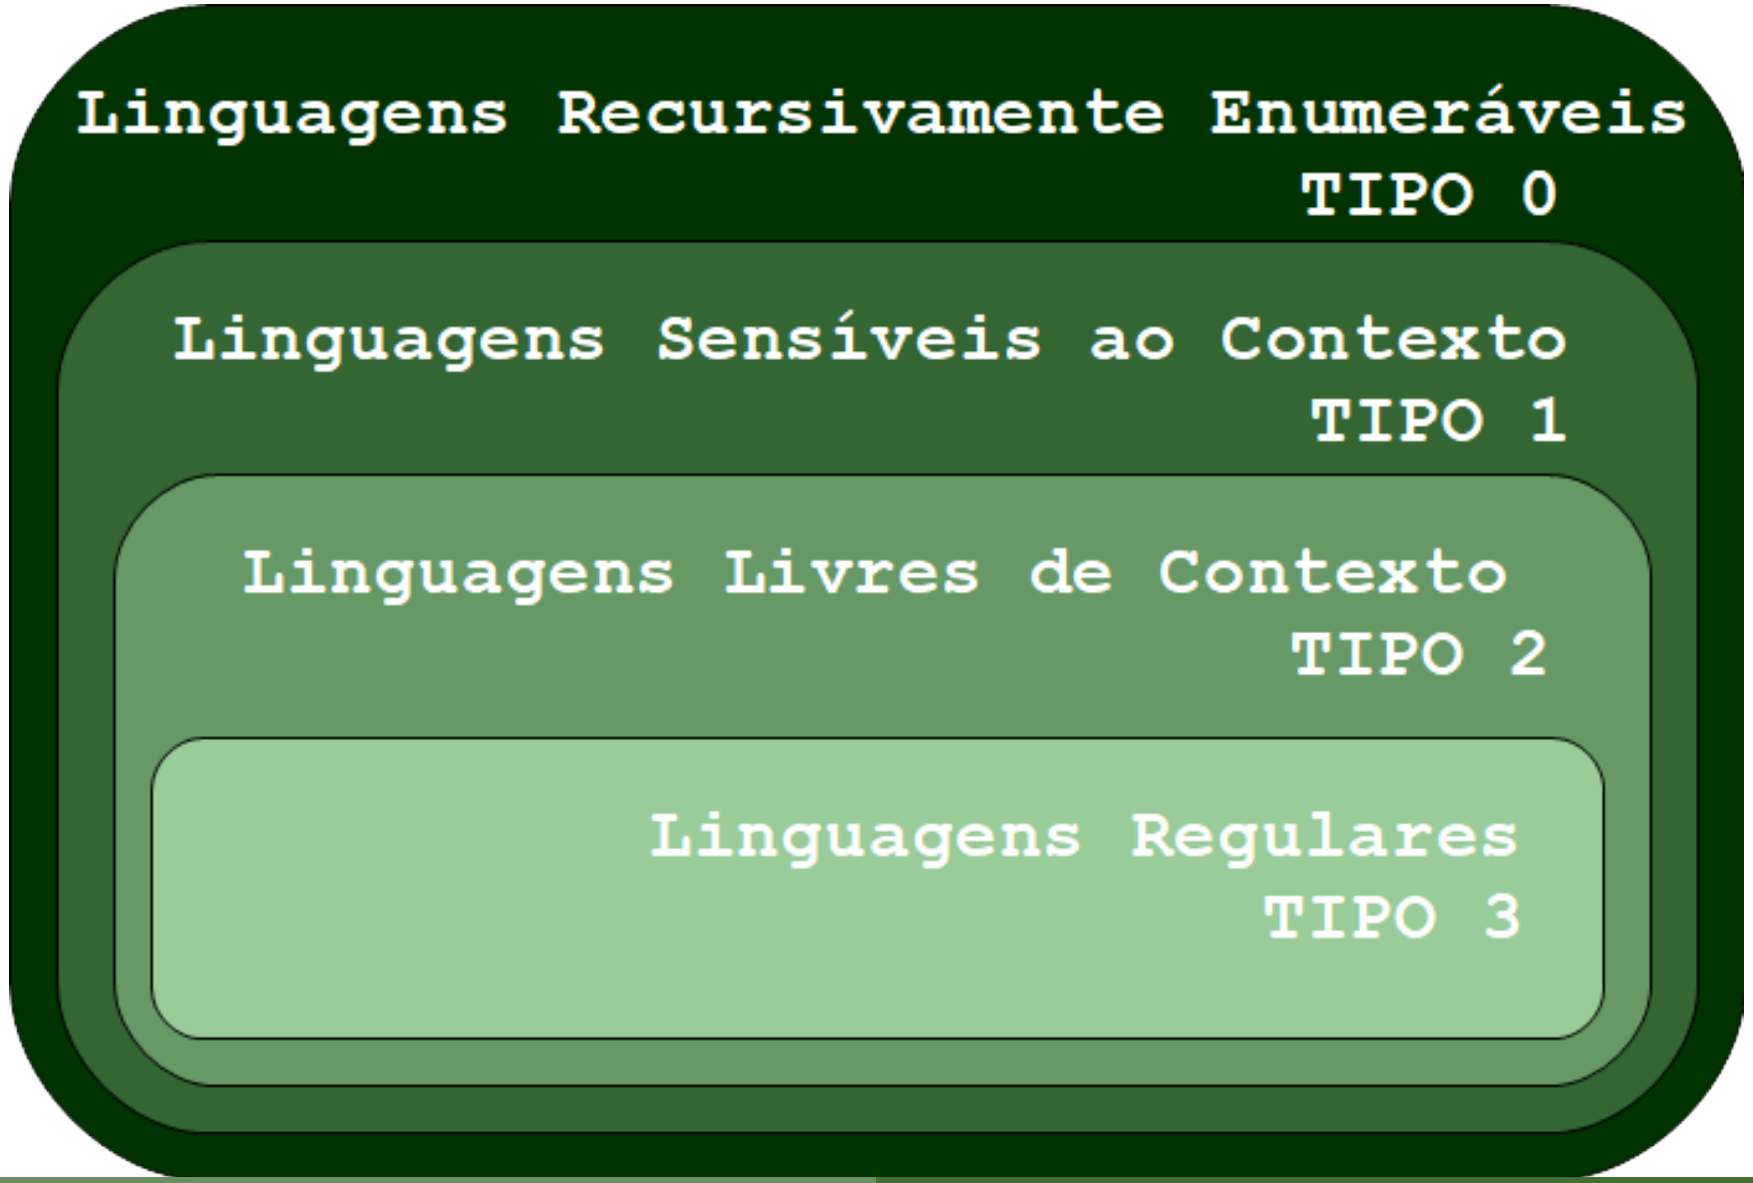

- A relação entre as gramáticas dos tipos 0, 1, 2 e 3 podem ser resumidas da seguinte forma:
  1. Toda gramática do tipo 3 é também do tipo 2 (livre de contexto).
  2. Nem toda gramática do tipo 2 é também do tipo 1 (sensível ao contexto).
     - São do tipo 1 apenas aquelas que não possuem produções $\alpha \rightarrow \beta$ em que $\beta \rightarrow \varepsilon$.
- Os critérios que levaram Chomsky a classificar as linguagens em quatro classes diferentes que constatam-se:
  - **semelhanças** para linguagens pertencentes a uma mesma classe e **diferenças** para linguagens pertencentes a classes diferentes, foram baseados nos seguintes aspectos:

Linguagens Formais

Hierarquia de Chomsky

1. O conjunto das propriedades exibidas pela linguagem.
2. As características estruturais mais significativas exibidas pela linguagem.
3. O modelo do reconhecedor mais simples necessário ao seu reconhecimento.

- As linguagens livres de contexto que não podem ser geradas por gramáticas lineares à esquerda ou à direita
  - distinguem-se das linguagens regulares por exibirem características de **aninhamento**, como é o caso da estruturação em blocos e comandos, ou o uso de parênteses em expressões aritméticas.

Linguagens Formais

Hierarquia de Chomsky

- Gramáticas livres de contexto possibilitam a formalização gramatical dos aninhamentos, ao passo que as gramáticas lineares não oferecem tal possibilidade.
- As linguagens sensíveis ao contexto que não podem ser geradas por gramáticas livres de contexto, diferenciam das linguagens livre de contexto
  - por conterem sentenças que exibem construções ou conjuntos de símbolos, cuja validade é vinculada à presença de construções associadas em regiões distintas da mesma cadeia.
  - Por exemplo, aquelas que existem entre a declaração e o uso de variáveis.
- Essas vinculações são características de linguagens do tipo 1, e recebem o nome de **sensibilidade** ou **dependência** de contexto.

Linguagens Formais

Hierarquia de Chomsky

- As linguagens irrestritas que não podem ser geradas por gramáticas sensíveis ao contexto, distinguem-se das linguagens sensíveis ao contexto por apresentarem características de **indecibilidade**:
  - demonstra-se que não há solução para o problema genérico de se decidir se uma cadeia qualquer pertence ou não à linguagem gerada por uma gramática (tipo 0).
- Sempre será possível reconhecer linguagens do tipo i com reconhecedores apropriados para linguagens do tipo $i-1, 1 \leq i \leq 3$.
- Existem quatro particularidades do modelo de reconhecedor: autômatos finitos, autômatos de pilha, as Máquinas de Turing com limitação de memória e as Máquinas de Turing sem limitação de memória.

- A associação das quatro classes de linguagens definidas pela Hierarquia de Chomsky, com os respectivos modelos de autômatos necessários ao seu reconhecimento:

Tipo	**Classe de linguagens**	**Modelo de gramática**	**Modelo de reconhecedor**
0	Recursivamente enumeráveis	Irrestrita	Máquina de Turing
1	Sensíveis ao contexto	Sensível ao contexto	Máquina de Turing com fita limitada
2	Livres de contexto	Livre de contexto	Autômato de pilha
3	Regulares	Linear (direita ou esquerda)	Autômato Finito