Conceitos de Linguagens Formais

Prof(a).Thatyana de Faria Piola Seraphim

Universidade Federal de Itajubá

thatyana@unifei.edu.br

Conceitos Básicos de Linguagens

- Existem vários conceitos básicos que estão associados às linguagens formais:
  - Símbolos e cadeias.
  - Linguagens propriamente ditas.
  - Gramáticas e reconhecedores.
- As gramáticas possuem grande importância na análise e na especificação formal da sintaxe de linguagens, principalmente das linguagens de programação.
  - Ao passo que os reconhecedores definem modelos que servem como base para a construção de analisadores léxicos e sintáticos nos compiladores e interpretadores das linguagens.
- O estudo das linguagens formais e dos autômatos viabiliza o desenvolvimento de técnicas eficientes para o uso das linguagens de programação, originando em seu estudo grande parte do interesse em linguagens de programação.

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- **Símbolos, palavras, átomos:** são representações gráficas, indivisíveis, empregadas na construção de **cadeias**.
- **Cadeias:** são formadas através da justaposição de um número finito de símbolos.
  - Os símbolos são obtidos de algum conjunto finito não-vazio, denominado **alfabeto**.
- Cada símbolo é considerado como uma unidade atômica, não importando a sua representação visual.
  - São exemplos de símbolos: *a, abc, begin, if, 5, 1024, 2.07e4*.
  - Não existe uma definição formal para **símbolos**.

Conceitos Básicos de Linguagens

Símbolos e Cadeias

Convenção adotada para símbolos, cadeias e alfabetos:

- **Símbolos**: letras minúsculas do alfabeto romano ($a,b,c,\ldots$).
- **Cadeias**: letras minúsculas do alfabeto romano ($r,s,t,u,\ldots$), ou letras minúsculas do alfabeto grego (α,β,γ).
- **Alfabetos**: letras maiúsculas do alfabeto grego (Σ,Γ,Δ).
- **Exemplo de alfabeto**: o conjunto Σ dos dígitos hexadecimais, em que cada elemento (dígito) desse conjunto corresponde a um determinado símbolo:

$$\Sigma = \{0,1,2,3,4,5,6,7,8,9,a,b,c,d,e,f\}$$

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- As cadeias que podem ser construídas a partir dos símbolos desse alfabeto correspondem aos numerais hexadecimais: 123, a0b56, fe5dc, b, abc, 55efff, ...
- O **comprimento** de uma cadeia é a quantidade de símbolos que a compõem.
- O comprimento de uma cadeia α é denotado por $|\alpha|$.

Cadeias	Comprimento
$\alpha = 1$	$\lvert\alpha\rvert = 1$
$\beta = 469$	$\lvert\beta\rvert = 3$
$\chi = ble60$	$\lvert\chi\rvert = 5$
$\phi = df$	$\lvert\phi\rvert = 2$

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- **Cadeia Elementar (unitária)**: é qualquer cadeia formada por um único símbolo.
  - Toda cadeia unitária tem comprimento 1.
- **Cadeia Vazia** ε: é uma cadeia formada por uma quantidade nula de símbolos, ou seja, uma cadeia que não contém nenhum símbolo.
  - Denotada por: $|\varepsilon| = 0$
- Duas cadeias, sejam elas elementares ou não, podem ser anexadas, formando uma só cadeia, através da operação de **concatenação**.
  - A operação de concatenação fornece como resultado uma **nova cadeia** formada pela **justaposição ordenada** dos símbolos que compõem seus operandos separadamente.

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- Denota-se a concatenação de duas cadeias α e β como $\alpha \cdot \beta$, ou $\alpha\beta$.
- **Exemplo**: considere o alfabeto $\Sigma = \{a, b, c, d\}$, e as cadeias $\alpha = abc, \beta = dbaca$ e $\sigma = a$
  - Concatenando a cadeia α com a cadeia β:

$$\alpha \cdot \beta = abcdbaca$$
$$|\alpha\beta| = |\alpha| + |\beta| = 3 + 5 = 8$$

  - Concatenando a cadeia β com a cadeia α:

$$\beta \cdot \alpha = dbacaabc$$
$$|\beta\alpha| = |\beta| + |\alpha| = 5 + 3 = 8$$

- Neste exemplo $\alpha\beta \neq \beta\alpha$

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- Concatenando a cadeia α com a cadeia σ:

$$\alpha \cdot \sigma = \alpha\sigma = abca$$
$$|\alpha\sigma| = |\alpha| + |\sigma| = 3 + 1 = 4$$

- Concatenando a cadeia σ com a cadeia β:

$$\sigma \cdot \beta = \sigma\beta = adbaca$$
$$|\sigma\beta| = |\sigma| + |\beta| = 1 + 5 = 6$$

- No caso da cadeia vazia ε, as seguintes relações, são válidas:
  1. $\alpha\varepsilon = \varepsilon\alpha = \alpha$
  2. $|\alpha\varepsilon| = |\varepsilon\alpha| = |\alpha|$

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- Uma cadeia α é um **prefixo** de outra cadeia β:
  - se for possível escrever β como $\alpha\gamma$.
- A cadeia α é dita **sufixo** de β se β puder ser escrita como $\gamma\alpha$.
- Em ambos os casos, é possível $\gamma = \varepsilon$.
- Quando $\gamma \neq \varepsilon$, diz-se que α é **prefixo próprio** ou **sufixo próprio** da cadeia β.
- A cadeia vazia ε pode ser considerada prefixo ou sufixo de qualquer cadeia.

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- Dado quatro cadeias: $\alpha, \beta, \gamma, \delta$:
  - Uma cadeia α é chamada de **subcadeia** de uma cadeia β sempre que $\beta = \gamma\alpha\delta$.
  - Se γ ou δ ou ambos forem vazios, a definição também se aplica.
  - Os **prefixos** e **sufixos** são casos particulares de subcadeias.
- Uma cadeia α é dita o **reverso** de uma cadeia β ($\alpha = \beta^R$), se α contiver os mesmos símbolos que β, porém justapostos no sentido inverso se:

$$\alpha = \sigma_1\sigma_2\ldots\sigma_{n-1}\sigma_n$$

então:

$$\beta = \sigma_n\sigma_{n-1}\ldots\sigma_2\sigma_1$$

Conceitos Básicos de Linguagens

Símbolos e Cadeias

- Por definição, $\varepsilon^R = \varepsilon$
- **Exemplo**: dado as cadeias $\alpha = 123abc$ e $\beta = d$
  - $\alpha^R = cba321$.
  - $\beta^R = d$.
- Convenciona-se que σ^i representa a cadeia formada por i símbolos σ concatenados.
  - $a^0 = \varepsilon$.
  - $a^1 = a$.
  - $a^2 = aa$.
  - $a^3 = aaa$.

Conceitos Básicos de Linguagens

Linguagens

- Uma **linguagem formal** é um conjunto, finito ou infinito, de cadeias de comprimento finito, formadas pela concatenação de elementos de um alfabeto finito e não vazio.
- Além das operações definidas para conjuntos, como união, diferença, intersecção, etc; outras operações como a concatenação e os fechamentos, são fundamentais para a definição e o estudo das linguagens formais.
- É importante notar a diferença entre os conceitos:
  - **Cadeia Vazia (ε)**: cadeia vazia, ou seja, uma cadeia de comprimento zero.
  - **Conjunto vazio ($\emptyset$)**: denota uma linguagem que não contém nenhuma cadeia.
  - **Conjunto que contém apenas a cadeia vazia ($\{\varepsilon\}$)**: denota uma linguagem que contém uma única cadeia, a cadeia vazia.
    - $|\emptyset| = 0$ e $|\{\varepsilon\}| = 1$

Conceitos Básicos de Linguagens

Linguagens

- **Alfabetos**: são conjuntos finitos ou não-finitos de símbolos, onde através da concatenação são obtidas as **cadeias**.
- **Linguagens**: são conjuntos finitos (eventualmente vazios) ou infinitos de cadeias.
- **Cadeias**: são também chamadas de **sentença** de uma linguagem, no caso de ela pertencer à linguagem em questão.
- **Linguagens são, portanto, coleções de sentenças sobre um alfabeto.**

Conceitos Básicos de Linguagens

Linguagens

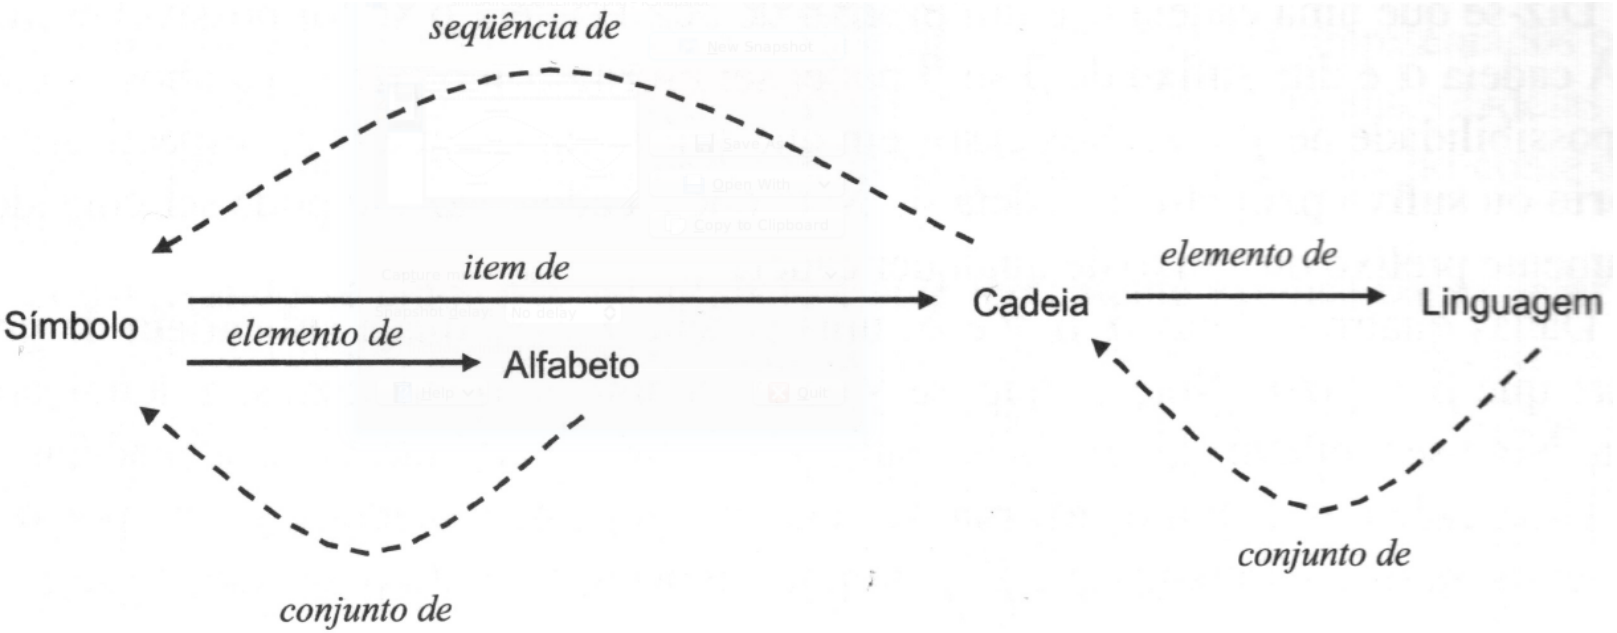

- Símbolo é elemento do alfabeto.
- Alfabeto é conjunto de símbolos.
- Símbolo é item de cadeia.
- Cadeia é sequência de símbolos.
- Cadeia é elemento de linguagem.
- Linguagem é conjunto de cadeias.

Conceitos Básicos de Linguagens

Linguagens

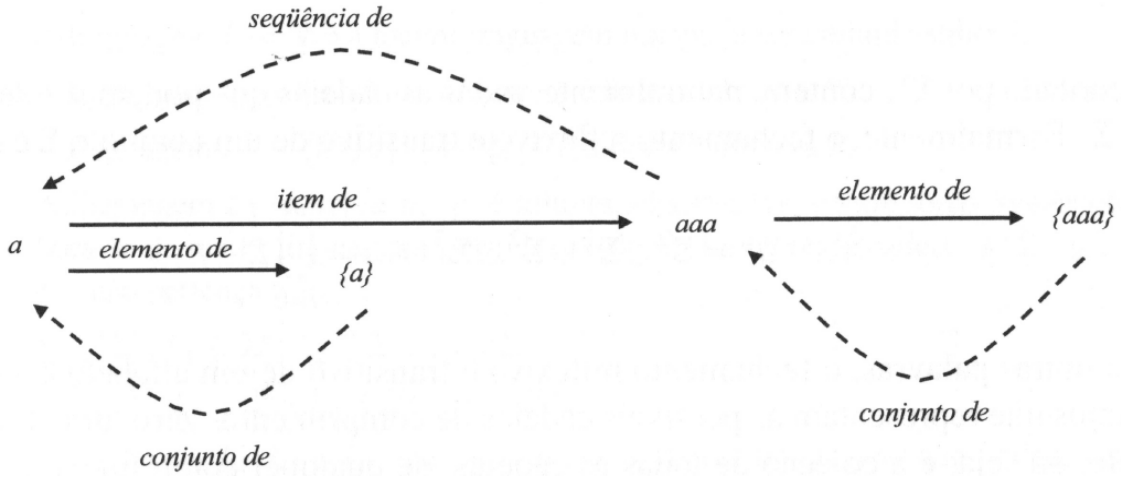

- O símbolo a é elemento do alfabeto $\{a\}$ e também um item da cadeia aaa, que por sua vez é elemento da linguagem $\{aaa\}$.
- A linguagem $\{aaa\}$ é um conjunto que contém a cadeia aaa.
- A cadeia aaa é uma sequência de símbolos a e o alfabeto $\{a\}$ contém o símbolo a.

Conceitos Básicos de Linguagens

Linguagens

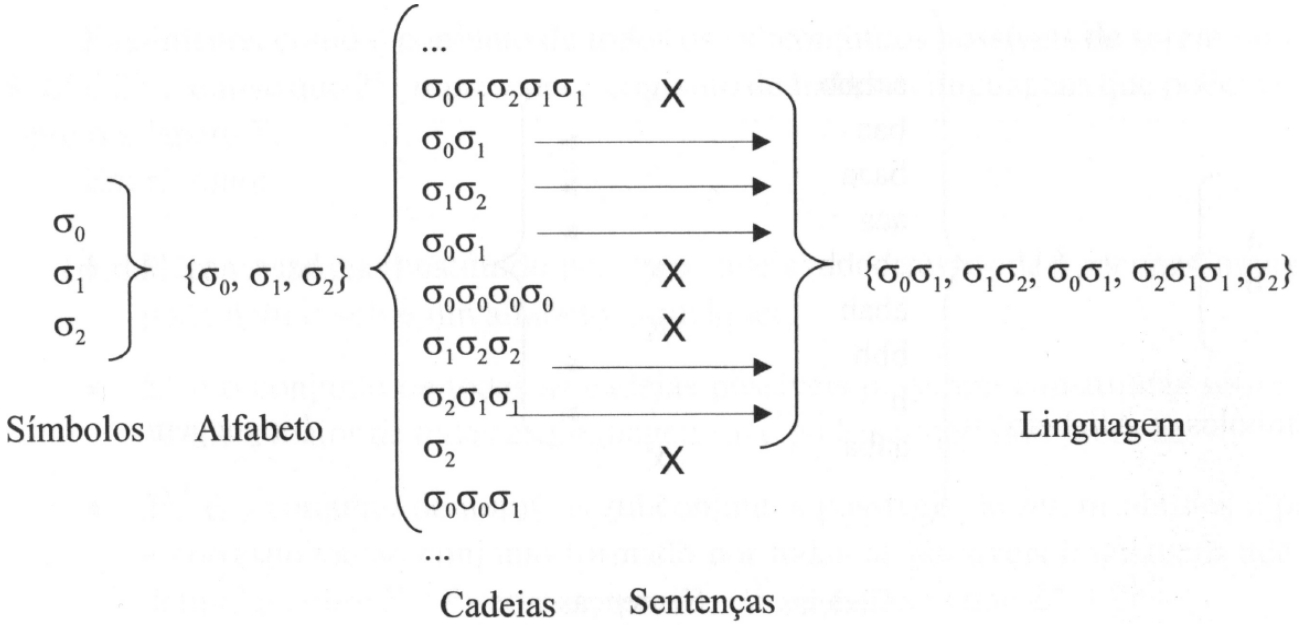

- Outra forma de entender as relações entre os conceitos:
  1. Um conjunto de símbolos forma um alfabeto.
  2. A partir de um alfabeto (finito) formam-se (infinitas) cadeias.
  3. Determinadas cadeias são escolhidas para fazer parte de uma linguagem.
  4. Uma linguagem é um conjunto de cadeias, que são denominadas sentenças.

Conceitos Básicos de Linguagens

Linguagens

- A operação de **concatenação** de duas linguagens X e Y, denotada por $X \cdot Y$ ou simplesmente XY
  - corresponde a um conjunto Z formado pela coleção de todas as cadeias que possam ser obtidas pela concatenação de cadeias $x \in X$ com cadeias $y \in Y$, nesta ordem.
- Formalmente:

$$Z = X \cdot Y = XY = \{xy | x \in X \ e \ y \in Y\}$$

- A concatenação $\Sigma\Sigma$, que gera cadeias de comprimento 2 formadas sobre um alfabeto Σ é representada por Σ^2.
- Por exemplo, $\Sigma = \{a, b, c\}$
  - $\Sigma^0 = \{\varepsilon\}$
  - $\Sigma^1 = \{a, b, c\}$
  - $\Sigma^2 = \{aa, ab, ac, ba, bb, bc, ca, cb, cc\}$
  - $\Sigma^3 = \{aaa, aab, aac, aba, abb, abc, \ldots, ccc\}$

Conceitos Básicos de Linguagens

Linguagens

- O **fechamento reflexivo e transitivo** de um alfabeto Σ é definido como o conjunto infinito que contém todas as possíveis cadeias que podem ser construídas sobre o alfabeto dado, incluindo a cadeia vazia.
- Esse conjunto é denotado por Σ^*, contém todas as cadeias que podem ser definidas sobre o alfabeto Σ.

Definição de Fechamento Reflexivo

- É a união de todos os conjuntos que representam as possíveis cadeias de comprimento zero, um, dois, três e assim por diante.
- É a coleção de todas as cadeias de qualquer comprimento que possam ser formadas por concatenação a partir dos símbolos do alfabeto.

Conceitos Básicos de Linguagens

Linguagens

- A definição de uma linguagem pode ser formulada de maneira mais rigorosa com o auxílio da operação de fechamento reflexivo e transitivo:
  - sendo uma linguagem qualquer coleção de cadeias sobre um determinado alfabeto Σ;
  - e como Σ^* contém todas as possíveis cadeias sobre Σ;
  - então toda e qualquer linguagem L sobre um alfabeto Σ poderá ser definida como sendo um subconjunto de Σ^*, ou seja, $L \subseteq \Sigma^*$.
- O **fechamento transitivo** de um alfabeto Σ, denotado por Σ^+. é definido de maneira análoga ao fechamento reflexivo e transitivo, diferindo apenas por não incluir o conjunto Σ^0.

Conceitos Básicos de Linguagens

Linguagens

- As linguagens de programação normalmente correspondem a um subconjunto próprio do fechamento reflexivo e transitivo do alfabeto sobre o qual as suas cadeias são construídas.
- Assim, são necessários métodos e notações que permitam dentro do conjunto de fechamento, identificar as cadeias que efetivamente pertencem à linguagem que estiver sendo definida.
- Outro aspecto importante referente à definição das linguagens formais, é o fato de que em sua maioria, as linguagens de interesse contêm uma quantidade infinita (um número finito, porém muito grande) de cadeias.
- Existe um interesse muito grande em relação à métodos que permitam especificar linguagens, sejam elas finitas ou não, através de representações finitas.

Conceitos Básicos de Linguagens

Linguagens

- Nem todas as linguagens podem ser representadas por meio de uma especificação finita.
- Existem três métodos que são empregados para a representação finita de linguagens:
  - **Gramáticas**: correspondem a especificações finitas de dispositivos de geração de cadeias.
    - Um dispositivo deve ser capaz de gerar toda e qualquer cadeia pertencente à linguagem definida pela gramática e nada mais.
    - As cadeias não pertencentes à linguagem não devem poder ser geradas pela gramática em questão.
    - Essa forma de especificação é aplicável para linguagens finitas e infinitas.

Conceitos Básicos de Linguagens

Linguagens

- Existem três métodos que são empregados para a representação finita de linguagens:
  - **Reconhecedores**: correspondem a especificações finitas de dispositivos de aceitação de cadeias.
    - O dispositivo deverá aceitar toda e qualquer cadeia pertencente à linguagem por ele definido, e rejeitar todas as cadeias não pertencentes à linguagem.
    - O método é aplicável para a especificação formal de linguagens finitas e infinitas.

Conceitos Básicos de Linguagens

Linguagens

- Existem três métodos que são empregados para a representação finita de linguagens:
  - **Enumerações**: relacionam, de forma explícita e exaustiva, todas as cadeias pertencentes à particular linguagem a ser especificada.
    - Toda e qualquer cadeia pertencente à linguagem deve constar desta relação.
    - As cadeias não pertencentes à linguagem não fazem parte dessa relação.
    - Aplicam-se apenas para a especificação de linguagens finitas e preferencialmente não muito extensas.
- As gramáticas e os reconhecedores, além de fornecer uma grande concisão na representação de linguagens de cardinalidade elevada, também podem ser empregados na definição de linguagens infinitas, ao contrário das enumerações.

Conceitos Básicos de Linguagens

Linguagens

- Em contraste com o que ocorre com as enumerações, as gramáticas e os reconhecedores possibilitam uma percepção melhor da estrutura sintática inerente às sentenças das linguagens por eles definidas.
- Uma gramática é **equivalente** a um reconhecedor se duas condições forem simultaneamente verificadas:
  1. Toda cadeia gerada pela gramática é também aceita pelo reconhecedor.
  2. Toda cadeia aceita pelo reconhecedor é também gerada pela gramática.

Conceitos Básicos de Linguagens

Linguagens

- Dado a gramática G e o reconhecedor M, definidos através da linguagem gerada e aceita:
  - $G|L_1(G) = \{\alpha \in \{a,b\}^* |$ o primeiro símbolo de α é "a"$\}$
  - $M|L_2(M) = \{\beta \in \{a,b\}^*\}|$ o primeiro símbolo de β é "a" e o último símbolo é "b"$\}$
- Portanto:
  - $L_1 = \{a, aa, ab, aaa, aab, aba, abb, aaa \ldots\}$
  - $L_2 = \{ab, aab, abb, aaab, aabb, abab, abbb \ldots\}$
- As linguagens representam dois componentes básicos:
  - **Sintaxe**: refere-se à apresentação da linguagem sobre o significado associado à mesma.
  - **Semântica**: o significado que se atribui a uma cadeia, ou conjunto de cadeias de uma mesma linguagem, deriva do significado que se atribui às construções da linguagem.