Gramáticas e Reconhecedores

Prof(a).Thatyana de Faria Piola Seraphim

Universidade Federal de Itajubá

thatyana@unifei.edu.br

Gramáticas

- As gramáticas são também conhecidas como **dispositivos generativos, dispositivos de síntese** ou ainda **dispositivos de geração de cadeias**.
- As gramáticas constituem sistemas formais baseados em regras de substituição, através dos quais é possível sintetizar o conjunto das cadeias que compõem uma determinada linguagem.
- Esse conceito pode ser ilustrado através do significado do termo **gramática**: o livro através do qual são aprendidas as regras que indicam como falar e escrever corretamente um idioma.

Gramáticas

- As regras assim definidas especificam combinações válidas dos símbolos que compõem o alfabeto (verbos, substantivos, adjetivos, etc).
  - Isso é feito com o auxílio de entidades abstratas denominadas classes sintáticas: sujeito, predicado, etc.
- Por exemplo, a frase "O menino atravessou a rua distraidamente":
  - É considerada correta do ponto de vista gramatical.
  - Ela obedece a uma das inúmeras regras de formação de frases, baseada no padrão **sujeito + predicado**.
- Assim como ocorre no caso das linguagens naturais, as **linguagens formais** também podem ser especificadas através de "gramáticas" a elas associadas.

Gramáticas

- Diferentemente das gramáticas das linguagens naturais, que são descritas por intermédio de linguagens naturais (muitas vezes a mesma que está sendo descrita pela gramática).
  - As gramáticas das linguagens formais são descritas utilizando notações matemáticas rigorosas que visam evitar dúvidas na sua interpretação.
- Essas notações recebem a denominação de **metalinguagens** – linguagens que são empregadas para definir outras linguagens.

Gramáticas

- Uma gramática G pode ser definida como sendo uma quádrupla: $G = \{V, \Sigma, P, S\}$, onde:
  - **V** é o **vocabulário** da gramática; corresponde a um conjunto (finito e não-vazio) de símbolos.
  - Σ é o conjunto (finito e não-vazio) dos símbolos **terminais** da gramática; também denominado **alfabeto**.
  - **P** é o conjunto (finito e não-vazio) de **produções** ou **regras de substituição** da gramática.
  - **S** é a **raiz** (ou **simbolo inicial**) da gramática, $S \in V$.

Gramáticas

- Define-se $N = V - \Sigma$ como sendo o conjunto dos símbolos **não-terminais** da gramática:
  - Σ: corresponde ao conjunto de símbolos que podem ser unidos para compor as sentenças da linguagem que se está definindo.
  - N: corresponde ao conjunto de símbolos intermediários utilizados na estruturação e na geração de sentenças, sem no entanto, fazer parte das mesmas.
- Σ, N e P são conjuntos finitos e não-vazios.

Gramáticas

- P é o conjunto das produções gramaticais, que obedecem à forma geral:

$$\alpha \rightarrow \beta, com\ \alpha \in V^* N V^* e\ \beta \in V^*$$

- α é uma cadeia qualquer constituída por elementos de V, contendo pelo menos um símbolo não-terminal.
- β é uma cadeia qualquer, eventualmente vazia, de elementos de V.

Gramáticas

- **Forma sentencial**: qualquer cadeia obtida pela aplicação recorrente das seguintes regras de substituição:
  1. S (a raiz da gramática) é por definição uma forma sentencial.
  2. Seja $\alpha\rho\beta$ uma forma sentencial, com α e β cadeias quaisquer de terminais e/ou não-terminais da gramática, e seja $\rho \rightarrow \gamma$ uma produção da gramática.
     - A aplicação dessa produção à forma sentencial, substituindo a ocorrência de ρ por γ, produz uma nova forma sentencial $\alpha\gamma\beta$.

Gramáticas

- Denota-se a substituição definida como **derivação direta** por:

$$\alpha\rho\beta \Rightarrow_G \alpha\gamma\beta$$

- O índice *"G"* designa o fato de que a produção aplicada, no caso $\rho \rightarrow \gamma$, pertence ao conjunto de produções que define a gramática G.
- Nos casos em que a gramática puder se facilmente identificada, admite-se a eliminação de referências explícitas a ela.
- A distinção gráfica e de significado que se faz entre o símbolo empregado na denotação das produções da gramática ($\rightarrow$) e o símbolo utilizado na denotação das derivações ($\Rightarrow$).

Gramáticas

- **Derivação** é uma sequência de zero ou mais derivações diretas, como, por exemplo $\alpha \Rightarrow \beta \Rightarrow \ldots \Rightarrow \mu$. A derivação pode ser abreviada como $\alpha \Rightarrow^* \mu$.
- **Derivações não-triviais** são derivações em que ocorre a aplicação de pelo menos uma produção. Essas derivações são denotadas por $\alpha \Rightarrow^+ \mu$.
- Se, pela aplicação de uma derivação não-trivial à raiz S de uma gramática, for possível obter uma cadeia w formada por símbolos terminais.
  - w, além de ser uma forma sentencial, é também uma **sentença**, e denota-se a sua derivação por:

$$S \Rightarrow^+ w$$

Gramáticas

- Gramáticas são sistemas formais baseados na substituição de uma cadeia, com o lado esquerdo de uma regra de produção, pela cadeia correspondente ao lado direito da mesma regra.
  - Visando com isso, ao final de uma sequência de substituições, a obtenção de uma cadeia sobre Σ.
- O processo de substituição tem **início** sempre a partir da raiz S da gramática e é **finalizado** assim que for obtida uma forma sentencial isenta de símbolos não-terminais, isto é, assim que obtiver uma sentença.
- **Linguagem definida pela gramática G, ou L(G)**: é o conjunto de todas as sentenças w geradas por uma gramática G.

$$L(G) = \{w \in \Sigma^* | S \Rightarrow^+ w\}$$

Gramáticas

- Diferentes sequências de produções aplicadas à raiz da gramática possibilitam a geração de diferentes sentenças da linguagem.
- Muitas vezes, há mais de uma alternativa de substituição para um mesmo trecho de uma forma sentencial, ou ainda, pode haver mais de um trecho em uma mesma forma sentencial que pode ser objeto de substituição pelo lado direito de alguma produção.
- A identificação correta das sentenças de uma linguagem deve ser feita levando em conta a possibilidade de ocorrência de todos esses fatores durante o processo de síntese de cadeia.

Gramáticas

- Existem muitas notações que podem ser utilizadas na definição gramatical de uma linguagem formal e de programação.
- A **notação algébrica** é uma das mais utilizadas.
- Existem diversas outras metalinguagens que são bastante empregadas para representar dispositivos generativos.
- A escolha de uma metalinguagem varia de acordo com o tipo da linguagem que estiver sendo definida.
- Existem outras notações que podem ser usadas para representar diversos tipos de linguagens como, por exemplo:
  - Expressões regulares, BNF (*Backus-Naur Form*), a Notação de *Wirth* (Expressões Regulares Estendidas) e os Diagramas de Sintaxe (Diagramas Ferroviários).

Reconhecedores

- Os reconhecedores são também conhecidos como **dispositivos cognitivos, dispositivos de aceitação, aceitadores sintáticos** ou simplesmente **autômatos**.
- **Reconhecedores** são sistemas formais capazes de aceitar todas as sentenças que pertençam a uma determinada linguagem, rejeitando todas as demais.
  - Por esse motivo, constituem uma forma alternativa às gramáticas para a representação finita de linguagens.
- Os reconhecedores são mais estudados se forem utilizadas notações diversas, cada qual apropriada para uma classe de linguagem.

Reconhecedores

- Os reconhecedores apresentam quatro componentes fundamentais:
  1. **Memória (fita)**: contendo o texto de entrada do reconhecedor.
  2. **Cursor**: indica o próximo elemento da fita a ser processado.
  3. **Máquina de estados**: sem memória.
  4. **Memória auxiliar**: opcional.

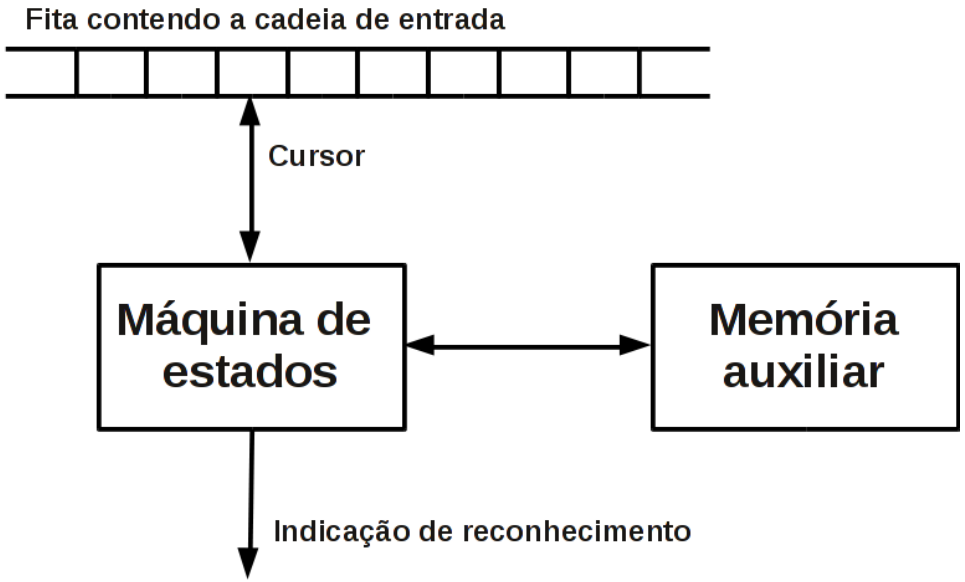

Fita de Entrada

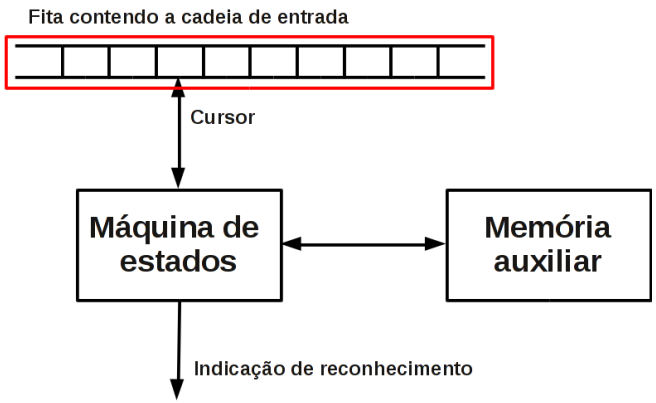

- A fita de entrada contém a cadeia a ser analisada pelo reconhecedor.
- É dividida em células.
  - Cada célula pode conter um único símbolo da cadeia de entrada, pertencente ao alfabeto de entrada escolhido pelo reconhecedor.

Reconhecedores

- A cadeia de entrada é disposta da esquerda para a direita, sendo seu primeiro símbolo colocado na posição mais à esquerda da fita.
- Dependendo do tipo de reconhecedor, a fita (ou conjunto de fitas) de entrada pode apresentar comprimento finito ou infinito.
- Quando a fita apresenta comprimento infinito, ela pode ter ou não limitação à esquerda ou à direita.
- A cadeia de entrada registrada na fita de entrada pode estar delimitada por símbolos especiais.
  - Esses símbolos especiais, podem não pertencer ao alfabeto de entrada, à sua esquerda ou à direita, porém isso não é obrigatório.

Cursor

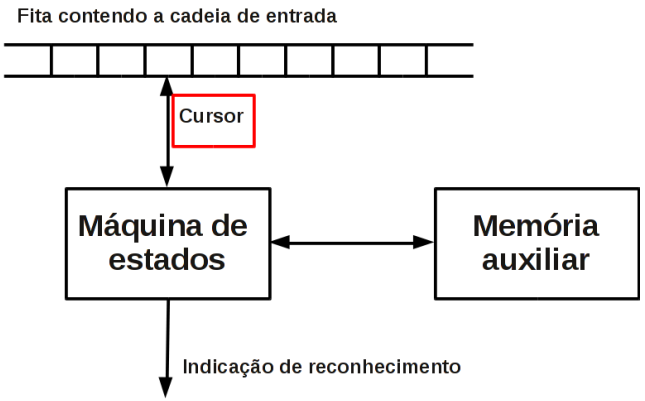

- É um cabeçote de acesso que realiza a leitura dos símbolos gravados na fita de entrada.
- O cursor sempre aponta o próximo símbolo da cadeia a ser processado.
- Os movimentos do cursor são controlados pela máquina de estados, e podem ser:

Reconhecedores

- **Unidirecionais**: podendo deslocar-se para um lado apenas, tipicamente para a direita.
- **Bidirecionais**: podendo deslocar-se para a esquerda e para a direita.
- Determinados tipos de reconhecedores utilizam o cursor não apenas para lerem os símbolos da fita de entrada.
  - Mas também para escreverem sobre a fita, substituindo símbolos nela presentes por outros.
  - Isso é feito de acordo com comandos determinados pela máquina de estados.

Reconhecedores

Máquina de Estados

- A máquina de estados funciona como um controlador central do reconhecedor, e contém uma coleção finita de **estados** e **transições**.
  - Os **estados** são responsáveis pelo registro de informações colhidas no passado, mas consideradas relevantes para decisões futuras.
  - As **transições** promovem as mudanças de estado da máquina em sincronismo com as operações efetuadas através do cursor sobre a fita de entrada.

Reconhecedores

- A máquina de estados finitos pode utilizar uma memória auxiliar para armazenar ou consultar outras informações (necessárias ao completo reconhecimento da cadeia), também coletadas ao longo do processamento.

Memória Auxiliar

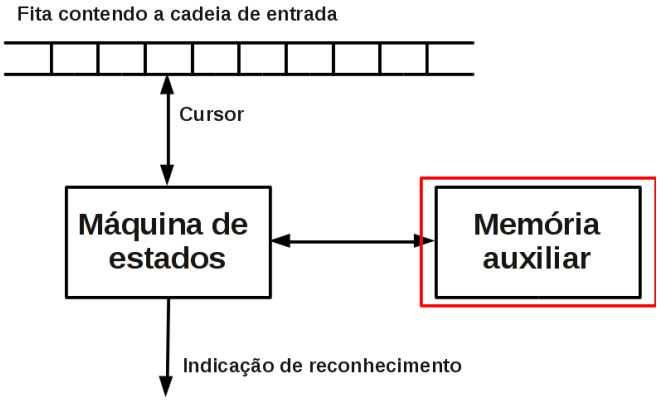

- A memória auxiliar é opcional, e torna-se necessária apenas em reconhecedores de linguagens que apresentam uma certa complexidade.

Reconhecedores

- A memória auxiliar assume a forma de uma estrutura de dados de baixa complexidade, como por exemplo, uma pilha.
- As informações registradas na memória auxiliar são codificadas com base em um **alfabeto de memória**.
  - Todas as operações de manipulação de memória auxiliar fazem referência apenas aos símbolos que compõem esse alfabeto.
- Os elementos dessa memória são referenciados através de um **cursor auxiliar** que poderá coincidir com o próprio cursor da fita de entrada.
  - Seu tamanho não é obrigatoriamente limitado e, por definição, seu conteúdo pode ser consultado e modificado.

Reconhecedores

- Os componentes de um reconhecedor genérico e as diversas formas como um deles pode se apresentar são:

$$\text{Reconhecedor}\begin{cases}\text{Máquina de Estados}\{\ \text{Finita}\\ \text{Fita de entrada + Cursor}\begin{cases}\text{Limitada / Não limitada}\\ \text{Leitura apenas / Leitura e escrita}\\ \text{Direita apenas / Direita e esquerda}\end{cases}\\ \text{Memória auxiliar + Cursor}\begin{cases}\text{Não limitada}\\ \text{Leitura e escrita}\end{cases}\end{cases}$$

- A operação de um reconhecedor baseia-se em uma sequência de movimentos que o conduzem, de uma **configuração inicial**, para alguma **configuração de parada**.
  - A configuração de parada é indicativa do sucesso ou do fracasso da tentativa de reconhecimento da cadeia de entrada.

Reconhecedores

- Cada **configuração** de um autômato é caracterizada pela quádrupla:
  1. Estado.
  2. Conteúdo da fila de entrada.
  3. Posição do cursor.
  4. Conteúdo da memória auxiliar.
- A **configuração inicial** de um autômato é definida como sendo aquela em que as seguintes condições são verificadas:
  1. **Estado**: inicial, único para cada reconhecedor.
  2. **Conteúdo da fila de entrada**: com a cadeia completa a ser analisada.
  3. **Posição do cursor**: apontando para o símbolo mais à esquerda da cadeia.
  4. **Conteúdo da memória auxiliar**: inicial, predefinido e único.

Reconhecedores

- A **configuração final** de um autômato é aquela na qual as seguintes condições são obedecidas:
  1. **Estado**: algum dos estados finais, que não são necessariamente únicos no reconhecedor.
  2. **Conteúdo da fila de entrada**: inalterado ou alterado, em relação à configuração inicial, conforme o tipo do reconhecedor.
  3. **Posição do cursor**: apontando para a direita do último símbolo da cadeia de entrada ou apontando para qualquer posição da fita, conforme o tipo do reconhecedor.
  4. **Conteúdo da memória auxiliar**: final e predefinido, não necessariamente único ou idêntico ao da configuração inicial.

Reconhecedores

- **Transição**: é a especificação de uma possibilidade de **movimentação** entre uma configuração e outra.
- A movimentação do autômato da configuração corrente para uma configuração é feita levando em conta todas as transições passíveis de serem aplicadas pelo reconhecedor à configuração corrente.
- Uma transição mapeia triplas formadas por:
  - Estado corrente em triplas formadas por próximo estado.
  - Símbolo correntemente apontado pelo cursor da fita de entrada em triplas formadas por símbolo que substituirá o símbolo apontado pelo cursor da fita de entrada e o sentido do deslocamento do cursor.
  - Símbolo corrente apontado pelo cursor da memória auxiliar em triplas formadas por símbolo que substituirá o símbolo corrente apontado pelo cursor da memória auxiliar.

Reconhecedores

- A identificação das transições passíveis de serem aplicadas a uma determinada configuração é determinada pela máquina de estados.
  - A máquina de estados também é responsável pelo deslocamento do cursor, acompanhado de uma substituição do símbolo lido na fita de entrada e também por eventual modificação do conteúdo da memória auxiliar.
- Uma vez que o autômato exibir várias transições que sejam aplicáveis a uma dada configuração
  - não significa que haja mais de uma possibilidade de movimentação na configuração.
- **Transição em vazio**: são transições que permitem a movimentação do autômato sem levar em conta os símbolos da cadeia de entrada em uma mesma configuração.

Reconhecedores

- Um autômato **aceita (reconhece)** uma cadeia se lhe for possível atingir alguma configuração final a partir da configuração inicial, caso contrário, diz-se que o autômato **rejeita** a cadeia.
- É possível que ocorram, durante o reconhecimento de uma cadeia de entrada, configurações para as quais se apresentem:
  - **Nenhuma movimentação**.
  - **Apenas uma movimentação**: a transição efetuada é chamada de determinística, dado que não existem outras opções de evolução para o autômato em tal configuração.
    - Quando todos os movimentos capazes de serem executados por um autômato forem movimentos determinísticos, independente da entrada, o autômato é conhecido como **determinístico**.

Reconhecedores

- É possível que ocorram, durante o reconhecimento de uma cadeia de entrada, configurações para as quais se apresentem:
  - **Diversas possibilidades distintas de movimentação**: todas as possibilidades devem ser consideradas, e o autômato deverá optar de forma aleatória, por todas as alternativas apresentadas até que uma das condições seja satisfeita:
    - Uma configuração final seja atingida.
    - Esgotadas todas as possibilidades, nenhuma configuração final possa ser atingida.
  - Um autômato com essa característica é denominado **não-determinístico**.

Reconhecedores

- Uma cadeia de entrada é aceita por ele se pelo menos uma das múltiplas sequências de movimentações realizadas pelo autômato for capaz de conduzi-lo a alguma configuração final, partindo da configuração inicial.
  - O autômato rejeita a cadeia de entrada quando, esgotadas todas as sequências de movimentações possíveis se não atingir uma configuração final qualquer.

Reconhecedores

- Os reconhecedores são representados como dispositivos cujas configurações são definidas como elementos do produto cartesiano: $Q \times (\Sigma^* \times \Sigma^*) \times \Gamma$, onde:
  - Q é o conjunto de estados.
  - Σ é o alfabeto de entrada do reconhecedor.
  - Γ é o alfabeto de sua memória auxiliar.
- As configurações de um reconhecedor genérico podem ser representadas como triplas $(q, (\alpha, \beta), \gamma)$, onde:
  - q representa o estado assumido pela máquina de estados.
  - γ representa o conteúdo completo da memória auxiliar.
  - (α, β) indica ao mesmo tempo o conteúdo completo da fita de entrada e a posição do cursor sobre a fita.
    - α representa o conteúdo da fila à **esquerda** do cursor.
    - β representa o conteúdo da fita à **direita** do cursor, incluindo o símbolo apontado pelo cursor na configuração considerada.

Reconhecedores

- Interpreta-se α como a parte da fita já analisada pelo reconhecedor e β a parte ainda a analisar.
- A **função de transição** especifica um conjunto de possibilidades de movimentação, podendo, em cada uma, produzir os seguintes efeitos sobre a configuração do autômato:
  1. Mudança de estado.
  2. Alteração da cadeia de entrada a partir da consulta do símbolo corrente e de sua substituição.
  3. Eventual modificação da cadeia de entrada sem que haja consulta do símbolo corrente.
  4. Eventual deslocamento do cursor da fita de entrada para a direita ou para a esquerda, após a aplicação da transição.

Reconhecedores

- A **função de transição** especifica um conjunto de possibilidades de movimentação, podendo, em cada uma, produzir os seguintes efeitos sobre a configuração do autômato:
  5. Alteração do conteúdo da memória auxiliar, a partir de um símbolo e de sua subsequente substituição.
  6. Deslocamento do cursor da memória auxiliar, de forma compatível com a maneira como a mesma estiver estruturada.
- Note, opcionalmente, que:
  7. É possível associar uma mesma configuração corrente a mais de uma nova configuração seguinte (uma forma de não-determinismo).
  8. É possível haver configurações para as quais não foram definidas possibilidades de movimentação.

Reconhecedores

- A **configuração inicial** de um reconhecedor pode ser escrita como: $(q_0, (\varepsilon, w), \gamma_0)$
  - $q_0 \in Q$ é o estado inicial.
  - $w \in \Sigma^*$ é a cadeia de entrada a ser analisada.
  - $\gamma_0 \in \Gamma^*$ é o conteúdo inicial da memória auxiliar.
- As **configurações finais** de um reconhecedor podem ser caracterizadas como $(q_F, (\alpha, \beta), \gamma_f)$:
  - $q_F \in Q_F$
  - $\gamma_F \in \Gamma_F$