Linguagens Livres de Contexto – Tipo 2

Prof(a) Thatyana de Faria Piola Seraphim

Universidade Federal de Itajubá

thatyana@unifei.edu.br

Linguagens Livres de Contexto

- As linguagens e as gramáticas livres de contexto foram inicialmente desenvolvidas com a intenção de permitir a formalização sintática das linguagens naturais.
- No entanto, as linguagens naturais são mais complexas do que a classe de linguagens representáveis através das gramáticas livres de contexto.
  - Diminuindo em muito, o interesse dos estudiosos das linguagens naturais pelas gramáticas desse tipo.
- Por outro lado, as linguagens livres de contexto despertaram interesse na comunidade científica ligada à área de computação.
  - Que via grandes possibilidades de aplicação dessa classe de linguagens na análise e na formalização de linguagens artificiais, em particular, as linguagens de programação.

Linguagens Livres de Contexto

- Em meados da década de 50, a linguagem FORTRAN já tinha sido definida, e algumas implementações experimentais estavam sendo usadas no desenvolvimento de aplicações.
- Como a teoria das linguagens ainda principiava o seu desenvolvimento, a linguagem FORTRAN foi originalmente especificada de maneira quase que totalmente empírica.
  - Sem que houvesse um sólido fundamento teórico e conceitual em seu projeto.
- Inúmeras dificuldades foram enfrentadas no início do projeto FORTRAN, as quais tiveram como consequência os seguintes registros de época:
  1. Elevada complexidade dos problemas de formalização sintática e de construção de aceitadores sintáticos das linguagens de programação.
  2. Arbitrariedade na imposição de restrições nos projetos de linguagens de alto nível, tornando mais difícil sua utilização por parte dos usuários.

Linguagens Livres de Contexto

- Praticamente não existiam métodos para a formalização sintática das linguagens de programação e para a construção de seus reconhecedores.
- O advento da teoria das linguagens e seu relacionamento com a teoria dos autômatos ocorreram justamente no momento em que a necessidade de métodos e técnicas havia se tornado bastante clara.
  - A fim de possibilitar a evolução das novas áreas de conhecimento emergentes dentro da computação: a das linguagens de programação e a dos compiladores.
- Nesse sentido, o papel das gramáticas livres de contexto foi extremamente importante.

Linguagens Livres de Contexto

- Por um lado, permitiu o desenvolvimento de notações adequadas para a formalização da sintaxe das linguagens artificiais.
- Por outro, possibilitou o desenvolvimento de técnicas muito eficiente de construção de reconhecedores sintáticos.
  - Algumas delas através de mapeamentos efetuados diretamente a partir das gramáticas das respectivas linguagens.
- Assim, as gramáticas livres de contexto contribuíram para desfazer a complexidade dos novos problemas que se apresentavam, simplificando-os consideravelmente.

Linguagens Livres de Contexto

- Um exemplo disso foi a definição da notação BNF, logo após a definição das gramáticas livres de contexto por Chomsky.
- A notação BNF (*Backus-Naur Form*) era também destinada à representação de gramáticas livres de contexto e foi concebida para o uso em linguagens de programação.
- Foi utilizada pela primeira vez na especificação da linguagem de programação Algol 60, tendo seu uso difundido até os dias de hoje.
- Graças ao grande desenvolvimento teórico verificado nas últimas décadas, tais problemas, longe de terem se tornado triviais, tiveram bem determinados os limites de sua complexidade.
  - Como consequência, a diversificação de métodos e resultados teóricos permite que os mesmos sejam tratados de forma rotineira no dia a dia do profissional da computação.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- **Gramática Livre de Contexto (GLC)**: é uma especificação para a estrutura sintática de uma linguagem de programação.
- GLC é muito similar à especificação da estrutura léxica de uma linguagem por expressões regulares, exceto que a GLC utiliza regras recursivas.
- As regras de uma gramática livre de contexto são definidas sobre um alfabeto ou um conjunto de símbolos.
- Os símbolos são *tokens* que representam cadeias de símbolos .

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

Uma GLC, é definida como $G = \{T, N, S, P\}$, onde:

- **Símbolos Terminais (T)**: são os símbolos básicos a partir dos quais as cadeias são formadas. Os símbolos terminais são os primeiros componentes dos *tokens* gerados pelos analisador léxicos. Exemplo: identificadores ou números.
- **Símbolos Não-terminais (N)**: são variáveis sintáticas que representam conjuntos de cadeias. Impõem uma estrutura hierárquica sobre a linguagem que é a chave para a análise sintática e tradução. Exemplo: palavras reservadas, operadores.
- **Símbolo Inicial (S)**: um símbolo não terminal é distinguido como o *símbolo inicial* e o conjunto de cadeias que ele representa é a linguagem gerada pela gramática.

- **Produções (P)**: especificam a forma como o símbolos terminais e não-terminais podem ser combinados para formar cadeias. Cada produção consiste em:
  - um símbolo não-terminal chamado de **cabeça** ou **lado esquerdo** da produção.
  - o símbolo $\rightarrow$. Em vez da seta pode ser usado : ou :=
  - um **corpo** ou o **lado direito** consiste em zero ou mais terminais e não-terminais. Os componentes do corpo descrevem uma forma de como as cadeias do não-terminal do lado esquerdo da produção podem ser construídas

Dada a gramática:

exp → *exp* + *termo*
exp → *exp* - *termo*
exp → *termo*
termo → *termo* * *fator*
termo → *termo* / *fator*
termo → *fator*
fator → (*exp*)
fator → **id**

- **Símbolos terminais**: +, -, *, /, id
- **Símbolos não-terminais**: *exp*, *termo* e *fator*
- **Símbolo inicial**: *exp*

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- **São símbolos terminais**
  1. letras minúsculas do inicio do alfabeto, como a,b,c.
  2. símbolos operadores como $+$, *, entre outros.
  3. símbolos de pontuação como parênteses, vírgula, entre outros.
  4. os dígitos 0, 1, ..., 9.
  5. cadeias em negrito como **id** ou **if**, cada um representando um único símbolo terminal.
- **São símbolos não-terminais**
  1. letras maiúsculas do início do alfabeto, como A,B,C.
  2. a letra S, que quando aparece indica o símbolo inicial.
  3. nomes em minúsculo e itálico.
  4. nas construções das linguagens de programação, letras maiúsculas podem ser usadas para representar símbolos não-terminais.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Letras maiúsculas do fim do alfabeto, como X, Y, Z, representam símbolos da gramática, ou seja, não-terminais e terminais.
- Letras minúsculas do fim do alfabeto, como $u, v, \ldots, z$ representam cadeias de terminais vazias.
- Letras gregas maiúsculas, por exemplo α, β, γ, representam cadeias de símbolos da gramática, possivelmente vazias.
  - uma produção genérica pode ser escrita como $A \rightarrow \alpha$, onde A é o lado esquerdo da produção e α representa o lado direito da produção.
- Um conjunto de produções $A \rightarrow \alpha_1$, $A \rightarrow \alpha_2, \ldots, A \rightarrow \alpha_n$, com um lado comum A, pode ser escrito como $A \rightarrow \alpha_1 \mid \alpha_2 \mid \ldots \mid \alpha_n$, onde $\alpha_1 \mid \alpha_2 \mid \ldots \mid \alpha_n$ são chamadas de **alternativas** para A

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- As gramáticas livres de contexto podem ser utilizadas para representar subconjuntos de linguagens naturais.
- Por exemplo:

  $< \textit{frase} > \rightarrow < \textit{sujeito} > < \textit{verbo} > < \textit{complemento} >$

  $< \textit{sujeito} > \rightarrow$ `O homem`

  $< \textit{sujeito} > \rightarrow$ `A mulher`

  $< \textit{verbo} > \rightarrow$ `leu`

  $< \textit{verbo} > \rightarrow$ `escreveu`

  $< \textit{complemento} > \rightarrow$ `um` $< \textit{adjetivo} >$ `livro`

  $< \textit{adjetivo} > \rightarrow$ `ótimo`

  $< \textit{adjetivo} > \rightarrow$ `péssimo`

  $< \textit{adjetivo} > \rightarrow \varepsilon$

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Os símbolos não-terminais em gramáticas livres de contexto podem ser utilizados para representar classes sintáticas bem definidas.
  - Permitindo um elevado grau de intuição e de clareza na interpretação e na estruturação das sentenças pertencentes à linguagem.
- A maior aplicação das gramáticas livres de contexto ocorre na formalização sintática das linguagens de programação de alto nível.
- A formalização completa de sua sintaxe exigiria dispositivos mais complexos, como é o caso das gramáticas do tipo 1.
  - Uma vez que a grande maioria das linguagens do tipo 1 apresenta dependências de contexto que não podem ser representadas por gramáticas do tipo 2.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- A simplicidade das gramáticas livres de contexto as torna muito atraentes para a representação formal da sintaxe das linguagens.
- As gramáticas livres de contexto constituem uma solução em que o rigor da definição sintática é sacrificado em favor do uso de uma notação mais intuitiva e fácil de ser manipulada do que as gramáticas do tipo 1.
- As gramáticas formais do tipo 1, devido à sua elevada complexidade de manipulação, não costumam ser utilizadas na prática para representar dependências de contexto em linguagens de programação.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- A característica que torna as gramáticas livres de contexto adequadas à formalização sintática das linguagens de programação é sua capacidade de representação de **construções aninhadas**.
- **Construções aninhadas** costumam ocorrer em linguagens de programação, por exemplo:
  - **Construção de expressões aritméticas**: onde subexpressões são delimitadas, através do uso de parênteses.
  - **Estruturação do fluxo de controle**: onde comandos internos são inseridos como parte integrante de outros externos.
  - **Estruturação do programa**: onde blocos, módulos, procedimentos e funções são empregados para criar diferentes escopos.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- As gramáticas livres de contexto, podem ser formalmente definidas como uma quádrupla (V, Σ, P, S):
  - V: conjunto finito e não-vazio dos símbolos terminais e não-terminais.
  - Σ: conjunto finito e não-vazio dos símbolos terminais; correspondente ao alfabeto da linguagem definida pela gramática.
  - P: conjunto finito e não-vazio das regras de produção, todas no formato $\alpha \rightarrow \beta$, com $\alpha \in (V - \Sigma)$ e $\beta \in V^*$.
  - S: raiz da gramática, $S \in (V - \Sigma)$.

Exemplo:

- Seja P o conjunto de regras abaixo:

$$
\begin{aligned}
\{E &\rightarrow T + E && (1)\\
E &\rightarrow T && (2)\\
T &\rightarrow F * T && (3)\\
T &\rightarrow F && (4)\\
F &\rightarrow (E) && (5)\\
F &\rightarrow a\} && (6)
\end{aligned}
$$

- Considere a sentença $a*(a+a)$. Ela pode ser obtida da seguinte sequência de derivações:

$$
\begin{aligned}
&E \Rightarrow T \Rightarrow F * T \Rightarrow a * T \Rightarrow\\
&a * F \Rightarrow a * (E) \Rightarrow a * (T + E) \Rightarrow\\
&a * (F + E) \Rightarrow a * (a + E) \Rightarrow\\
&a * (a + T) \Rightarrow a * (a + F) \Rightarrow a * (a + a)
\end{aligned}
$$

Produções aplicadas: 2, 3, 6, 4, 5, 1, 4, 6, 2, 4, 6.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- A linguagem gerada pela gramática corresponde a sentenças que representam expressões aritméticas formadas sobre o operando *a* com os operadores $*$ e $+$.
- Subexpressões delimitadas através de parênteses são admitidas, e podem ser compostas com base nas mesmas regras usadas para construir a expressão inicial.
- Não fazem parte da linguagem definida pela gramática, por exemplo, cadeias em que não haja plena correspondência do símbolo "(" com seu par ")."
  - Trata-se de uma linguagem que admite o aninhamento de expressões através do uso de parênteses como delimitadores.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- O aninhamento de construções é a característica que distingue as linguagens estritamente do tipo 2 das linguagens do tipo 3.
- Pertencem a uma linguagem estritamente do tipo 2 apenas e tão somente as sentenças em que:
  - para cada ocorrência de um delimitador "(", exista em correspondência a ocorrência de um outro através do qual se forma o par ")".
- A subcadeia situada entre esse par de delimitadores pode ser gerada através das mesmas regras válidas para a sentença completa, caracterizando o aninhamento de suas construções.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- As gramáticas livres de contexto permitem impor restrições adicionais àquelas que se podem construir em gramáticas regulares.
  - Podendo caracterizar subconjuntos das linguagens regulares que usam a propriedade determinada pelos aninhamentos sintáticos.
- Dessa forma, as gramáticas livres de contexto tornam-se muito úteis para a especificação de linguagens de programação.
- A representação de aninhamentos em gramáticas do tipo 2 decorre de uma propriedade característica das gramáticas deste tipo, chamada *Self-embedding Property*.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Um símbolo não-terminal Y é dito *self-embedding* (**auto-recursivo central**), se, a partir dele:
  - for possível derivar alguma forma sentencial em que o Y resurja, delimitado por cadeias não-vazias de terminais a sua esquerda e à sua direita.

$$Y \Rightarrow^* \alpha Y \beta, \ com \ \alpha, \beta \in \Sigma^+$$

- Um não-terminal Z é dito **auto-recursivo** se, a partir dele, for possível derivar de alguma forma em que Z ressurja, acompanhado de pelo menos uma cadeia não-vazia de terminais à sua esquerda ou à sua direita.

$$Z \Rightarrow \alpha Z \beta, \ com \ \alpha, \beta \in \Sigma^*, \alpha\beta \neq \varepsilon$$

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Se uma gramática livre de contexto G possui pelo menos um símbolo não-terminal auto-recursivo central, diz-se que G é **auto-embutida** (*self-embedded*).
- Um símbolo não-terminal **essencial** é aquele que não pode ser removido da gramática (ou substituído) sob pena de provocar modificações na linguagem sendo definida.
- Uma linguagem L é dita **estritamente livre de contexto**, ou livre de contexto não-regular, se e apenas se
  - todas as gramáticas que geram L forem auto-embutidas, ou seja, se todas elas possuírem pelo menos um símbolo não-terminal **auto-recursivo central essencial**.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- O simples fato de uma gramática ser auto-embutida não garante a não-regularidade da linguagem definida:
  - é possível identificar linguagens geradas por gramáticas com não-terminais auto-recursivos centrais que, nesse caso, não são essenciais.
- Uma produção é **não-essencial** à gramática, quando a sua inclusão no conjunto de produções em nada contribui para modificar a linguagem definidas pelas demais produções.
- A *Self-embedding Property* expressa a capacidade que têm as gramáticas livres de contexto para representarem aninhamentos sintáticos.

- Se $Y \Rightarrow^* \alpha Y \beta$, então, da aplicação sucessiva dessa sequência de derivações, resulta que $\alpha\alpha Y\beta\beta$, $\alpha\alpha\alpha Y\beta\beta\beta$ são formas sentenciais que geram sentenças pertencentes a $L(G)$.
- A cada subcadeia α é possível impor a existência de uma outra subcadeia β que estabeleça a correspondência com α.
- É importante notar que, as gramáticas regulares não exibem a *Self-embedding Property*, sendo esta uma característica das gramáticas livres de contexto não-regulares.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Quando se consideram linguagens especificadas através de gramáticas livres de contexto, deve-se considerar de que forma é feita a aceitação sintática de suas sentenças para fins de compilação e/ou interpretação.
- Quando se trata de efetuar o reconhecimento de sentenças
  - o que se busca é localizar uma sequência de produções que quando aplicadas à raiz da gramática, forneça como resultado, através da série de derivações, a sentença fornecida para análise.
- Sendo possível completar a derivação, diz-se que a sentença pertence à linguagem; caso contrário, ela não pertence à linguagem.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Para cada sentença pertencente à linguagem definida através da gramática livre de contexto, é possível identificar uma grande quantidade de sequências distintas de derivação.
  - Resultado de escolhas arbitrárias do símbolo não-terminal a ser substituído em cada passo da derivação, todas elas resultando na mesma sentença analisada.
- Na prática, costuma-se fixar alguns critérios de derivação de sentenças, para permitir a construção e a operação do reconhecedores sintáticos.

- Para restringir o número de escolhas que se tem na derivação de uma *string*, é útil exigir que, em cada etapa, a variável mais à esquerda seja substituída por um de seus corpos de produção.
- Esse tipo de derivação é conhecida como **derivação mais à esquerda**, que pode ser representada por $\underset{lm}{\Rightarrow}$ ou $\overset{*}{\underset{lm}{\Rightarrow}}$, para uma ou muitas etapas.
- É possível que em cada etapa a variável mais à direita seja substituída por um dos seus corpos. Nesse caso, é chamada de **derivação mais à direita** e os símbolos usados para indicar uma ou muitas etapas de derivação são: $\underset{rm}{\Rightarrow}$ ou $\overset{*}{\underset{rm}{\Rightarrow}}$

Convenções usadas para derivação de uma GLC:

1. Letras minúsculas próximas ao alfabeto (como a, b, e assim por diante), são símbolos terminais. Símbolos ou outros caracteres como + ou parenteses são terminais.
2. Letras maiúsculas próximas ao início do alfabeto (como A, B, e assim por diante), são variáveis.
3. Letras minúsculas próximas ao fim do alfabeto (como w ou z), são *strings* de terminais.
4. Letras maiúsculas próximas ao fim do alfabeto (como X ou Y), são terminais ou variáveis.
5. Letras gregas minúsculas (como α e β), são *strings* que consistem em terminais oe/ou variáveis.

- A derivação de uma forma sentencial em uma gramática livre de contexto é uma **derivação mais à esquerda** quando:
  - a substituição de um símbolo não-terminal pelo lado direito de uma produção que o define é feita substituindo sempre o não-terminal que ocorre mais à esquerda na cadeia que representa a forma sentencial em questão.

Derivação mais à esquerda

$$
\begin{aligned}
E &\Rightarrow T + E \\
&\Rightarrow F + E \\
&\Rightarrow a + E \\
&\Rightarrow a + T \\
&\Rightarrow a + F \\
&\Rightarrow a + a
\end{aligned}
$$

Produções aplicadas:

1, 4, 6, 2, 4, 6

- De maneira análoga, uma **derivação mais à direita** é aquela em que é sempre o não-terminal mais à direita, que é substituído pela sua definição.

Derivação mais à direita

$$
\begin{aligned}
E &\Rightarrow T + E \\
&\Rightarrow T + T \\
&\Rightarrow T + F \\
&\Rightarrow T + a \\
&\Rightarrow F + a \\
&\Rightarrow a + a
\end{aligned}
$$

Produções aplicadas:

1, 2, 4, 6, 4, 6

Derivações de diversos tipos

$$
\begin{aligned}
E &\Rightarrow T + E \\
&\Rightarrow F + E \\
&\Rightarrow F + T \\
&\Rightarrow a + T \\
&\Rightarrow a + F \\
&\Rightarrow a + a
\end{aligned}
$$

Produções aplicadas:

1, 4, 2, 6, 4, 6

- Devido ao elevado interesse pelas gramáticas livres de contexto, inúmeras notações foram desenvolvidas para facilitar a formalização sintática das linguagens,
  - permitindo criar definições mais legíveis e concisas do que as obtidas com a notação algébrica.

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Essas notações são conhecidas como **metalinguagens**, e permitem a representação de linguagens livre de contexto. A primeira e mais importante pe BNF (*Backus-Naur Form*).
- Na notação BNF:
  - Os símbolos não terminais são representados por textos delimitados pelos símbolos $<$ e $>$.
  - Para distingui-los dos símbolos terminais, o metassímbolos $\rightarrow$ é substituído por $::=$.
  - Todas as alternativas de substituição para um mesmo símbolos não terminal, são agrupadas, separando umas das outras como o metassímbolo $|$.
  - Os símbolos terminais são denotados sem delimitadores.

- Por exemplo, a gramática que representa expressões aritméticas aninhadas, sobre um operando "a", como os operadores de multiplicação e adição, pode ser representada da seguinte forma:

Gramática

$$
\begin{aligned}
&< E > ::= < T > + < E > \mid < T > \\
&< T > ::= < F > * < T > \mid < F > \\
&< F > ::= a \mid (< E >)
\end{aligned}
$$

Linguagens Livres de Contexto

Gramáticas Livres de Contexto

- Essa notação foi empregada pela primeira vez em 1960 e se tornou extremamente popular, por ter demonstrado na prática, a viabilidade de uso de uma notação formal para a representação da sintaxe de uma linguagem de programação.
  - Representando um dos primeiros resultados práticos advindos do interesse dos profissionais de computação pelas gramáticas livre de contexto.
- A notação BNF enfrenta hoje em dia, a concorrência de outras metalinguagens igualmente importantes, como por exemplo, a Notação de *Wirth*, dos Diagramas de Sintaxe, das Expressões regulares estendidas, entre outras.
- Apesar disso, a notação BNF continua sendo empregada, por ser mais adequada ao estudo teórico e conceitual das linguagens formais.